

Su experiencia. Mejores decisiones. Un modelo que aprende.

Machine learning para evaluar solicitudes,
explicar el riesgo y probar políticas de crédito.

Manuel Toral

Estrategia de IA · Ciencia de datos · Operación de modelos

Cada crédito deja información. Hagamos que trabaje para usted.

Su historial de solicitudes, decisiones y pagos puede convertirse en un criterio común para toda la operación.

Más señales, juntas.	Estimar el riesgo combinando variables y sus interacciones.
Menos variación operativa.	Aplicar el mismo modelo y registrar cada versión de la decisión.
Revisión mejor enfocada.	Ordenar expedientes para aprovechar la capacidad del equipo.
Políticas que se pueden probar.	Comparar escenarios antes de cambiar criterios y límites.

El score informa. La política define cómo actuar.

Una estimación comparable de riesgo para cada solicitud.

El analista consulta los factores relevantes. La financiera fija sus condiciones de aprobación, revisión y exposición.

ORIGINACIÓN

¿Qué expedientes revisar primero?

ASIGNACIÓN DE LÍNEAS

¿Qué monto cabe en el riesgo y la capacidad de pago?

GESTIÓN DE CARTERA

¿En qué segmentos cambió el perfil?

El monto requiere ingresos disponibles, obligaciones, plazos y política de la financiera; el score es uno de los insumos.

Un caso público para mostrar qué recibirá su equipo.

307,511

solicitudes con desenlace

8.07%

con dificultades de pago

12

variables utilizadas

Home Credit · Kaggle, 2018

Una base pública para mostrar preparación, comparación de modelos, explicaciones y monitoreo reproducibles.

“Dificultades” conserva la definición del concurso: atraso mayor a X días en alguna de las primeras Y cuotas; X e Y no fueron publicados.


La adaptación es parte del servicio

Incluye 21,703 registros “State servant”. Esa etiqueta laboral no acredita un convenio de descuento por nómina.

El caso no usa datos de su financiera ni mide desempeño en crédito de nómina mexicano.

Con la misma revisión, el modelo encuentra más casos.

Acierto entre expedientes seleccionados para revisión



2.36x

casos con dificultades
frente al azar observado

1,175 frente a 497, revisando los mismos 6,151 expedientes.

Todos seleccionan el 10% de la prueba. Las reglas son
ilustrativas; no son decisiones históricas de su comité.

Priorizar mejor también exige ver el costo de los errores.

De cada 100 expedientes marcados por LightGBM, alrededor de 19 presentaron dificultades.

Los otros 81 son falsas alarmas para esta clasificación. Por eso marcar significa **revisar**, no rechazar automáticamente.


El comité puede balancear carga de trabajo, riesgo no detectado y costo de frenar buenos clientes.

Desenlace observado	Marcado	No marcado
Con dificultades	1,175 VP · detectados	3,790 FN · omitidos
Sin dificultades	4,976 FP · falsas alarmas	51,562 VN · no marcados

Captura: 23.7% de todos los casos con dificultades.
F1: 0.211 · ROC-AUC: 0.664.

Cada score puede explicarse como una combinación de factores.

Caso de prueba · LightGBM · 6.74% de probabilidad estimada



Lectura del caso: educación e ingreso reducen el score; antigüedad y monto lo elevan. La combinación genera el resultado. Son asociaciones del modelo, no causas ni puntos porcentuales.

Antes de cambiar una regla, compare sus consecuencias.

Un laboratorio de decisiones con el historial disponible y supuestos visibles.

01

Qué se cambia

Capacidad de revisión, umbrales de riesgo, límites por segmento y criterios de monto.

02

Qué se observa

Solicitudes seleccionadas, falsos positivos, dificultades omitidas y exposición por grupo.

03

Cómo se decide

Comparación con la política actual y validación de negocio antes de desplegar.

Las simulaciones describen escenarios históricos. El ahorro y el efecto de nuevas líneas requieren costos, recuperación y validación con la cartera.

El modelo se vigila desde el primer lote.

DATO

¿Se puede confiar en la captura?

Campos, tipos, rangos, duplicados y faltantes. Los errores bloqueantes suspenden la puntuación.

POBLACIÓN

¿Cambió quién está solicitando?

Distribuciones y scores contra una referencia. El PSI señala cambios para investigar.

RESULTADO

¿Sigue prediciendo cuando llegan pagos?

Precisión, captura y calibración con desenlaces maduros, por segmento y cohorte.

Demo disponible por lotes. Historial por cohortes, conexión a sus sistemas y notificaciones forman parte de la integración propuesta.

La predicción es ligera. La inversión está en hacerla útil.

~20 ms

por 1,000 predicciones
LightGBM en CPU

Medición local del prototipo.
No incluye captura, red ni integración.

Un stack abierto y conocido

Python, scikit-learn, XGBoost y LightGBM; explicaciones SHAP; interfaz Streamlit.

Qué define el presupuesto

Preparación del historial, integración con sistemas, validación, documentación y monitoreo.

La cotización se construye con el alcance y la calidad de sus datos. No se presupuestan ahorros a partir de Kaggle.

Una fase que entrega hallazgos. Otra que los deja operando.

01	Datos, hallazgos y modelos	Inventario, limpieza y exploración de su historial; definición de impago y reconstrucción de la política actual. Calibro y comparo varios modelos contra la regla vigente. Entrega: reporte de hallazgos y un prototipo ejecutado localmente con sus datos. 20 h en 4 semanas más 5 h de soporte · \$20,000 MXN + IVA
02	Monitoreo en operación	Dashboard de monitoreo con sus datos, controles de calidad, alertas y corridas recurrentes, con acompañamiento al equipo que las revisa. Entrega: monitoreo operando y soporte acordado. 25 a 30 h · \$20,000 a \$24,000 MXN + IVA
03	Acompañamiento a largo plazo	Ajustes del modelo con desenlaces maduros, nuevas políticas y transferencia al equipo. Entrega: se define al cierre de la fase 2. Alcance y honorarios por definir

Tarifa: \$800 MXN por hora más IVA. La fase 1 es una entrega estática; la fase 2 deja algo operando. El calendario corre desde que recibo los datos.

Manuel Toral

Estrategia de IA, ciencia de datos y operación de modelos, con experiencia en fintech, empresa y sector público.

RappiCard México

Data Science Lead · 2022–2025

Modelos predictivos, fraude y evolución de infraestructura de ML.

Coca-Cola FEMSA

Liderazgo en AI/ML Ops e I+D · desde 2025

Entrega de productos analíticos, monitoreo y gobierno de modelos.

Consejo de la Judicatura Federal

Proyectos estratégicos · 2019–2022

Integración de información y coordinación en entornos institucionales.

Formación y transferencia

University of Chicago

Maestría en Políticas Públicas.

Tecnológico de Monterrey

Maestría en Inteligencia Artificial Aplicada.

Docencia y formación técnica en analítica e inteligencia artificial.

Experiencia aplicada a problemas de negocio reales.

Global Fund for Women

NLP · 2023-2026

Implementación de un pipeline de lenguaje natural generativo en producción para analizar información no estructurada.

Aplicación: motor analítico para un índice multinacional.

Tec de Monterrey + IEPC Jalisco

Automatización · 2024

Arquitectura de un pipeline con IA capaz de procesar más de 3,000 horas de medios.

Aplicación: procesamiento con requisitos de auditoría.

IDntify

Detección de fraude · 2022

Desarrollo, evaluación y despliegue de modelos predictivos de fraude, con gestión de infraestructura y presupuesto.

Aplicación: llevar un modelo desde el desarrollo hasta la operación.

Coca-Cola FEMSA

Optimización · desde 2026

Dirección de un equipo de ciencia de datos para desarrollar modelos de dimensionamiento de flota y logística.

Aplicación: conectar decisiones operativas con objetivos de negocio.

Convirtamos su historial en una decisión de negocio.

Definamos un piloto para responder una pregunta:

¿Podemos priorizar mejor el riesgo con la capacidad que ya tiene su equipo?

Primera sesión de trabajo

Alinear el objetivo, revisar un inventario de datos y acordar cómo se medirá el valor.

Manuel Toral

jmtoralcruz@gmail.com
linkedin.com/in/manuel-toral

Seis modelos. La mejora se mide, no se presume.

Modelo	ROC-AUC	Acierto ¹	Captura ¹	F1 ¹	Brier ²	MAE ² (pp)
Regresión logística	0.644	16.9%	21.0%	0.187	0.073	14.5
XGBoost	0.664	18.8%	23.3%	0.208	0.072	14.4
LightGBM	0.664	19.1%	23.7%	0.211	0.072	14.4
Logística + SMOTE-NC	0.639	16.4%	20.3%	0.181	0.073	14.5
XGBoost + SMOTE-NC	0.620	12.6%	15.6%	0.139	0.074	14.7
LightGBM + SMOTE-NC	0.621	12.1%	15.0%	0.134	0.073	14.7

SMOTE-NC no mejoró ninguna familia.
Se probó con 5 vecinos y razón 0.5, sólo en entrenamiento. Se conserva la prevalencia original en validación y prueba.

¹ Marcado del 10% de la prueba.
² Error de probabilidad: menor es mejor.
MAPE no aplica porque TARGET contiene ceros.

Una ruta por fases, con entregables en cada avance.

Hallazgos → Monitoreo en operación → Acompañamiento

01

Datos, hallazgos y modelos

Limpieza, exploración, definición de impago y varios modelos calibrados sobre su historial.

20 h + 5 de soporte · \$20,000 + IVA

HITO DE CIERRE

Reporte de hallazgos
y prototipo con sus datos.

02

Monitoreo en operación

Dashboard de monitoreo, controles de calidad, alertas y corridas recurrentes con su equipo.

25 a 30 h · \$20,000 a \$24,000

HITO DE CIERRE

Monitoreo operando
y soporte acordado.

03

Acompañamiento a largo plazo

Ajustes con desenlaces maduros, nuevas políticas y transferencia al equipo.

Por definir

HITO DE CIERRE

Se define al cierre
de la fase 2.

Tarifa única de \$800 MXN por hora más IVA. La fase 1 incluye 5 horas de soporte posteriores a la entrega y el calendario corre desde que recibo los datos.